L'organisme d'idéation, expliqué depuis zéro et sa place dans le programme de contrôle

Pour un lecteur qui ne sait rien du projet. Version 4, 10 novembre 2026. Rédigé par la session « attaquant informé » pour Lazar. Aucun résultat d'attaque contre le juge de l'organisme n'est rapporté ici : la section 9 est réservée à la session mère. Chaque affirmation renvoie à sa source (annexe). La version 1 a passé l'épreuve du lecteur neuf (dix réponses justes sur dix) ; la version 2 corrige une étiquette fausse et ajoute les définitions que ce lecteur a demandées ; la version 3 intègre le lien entre l'organisme et son objectif ultime validé par Lazar, corrige l'état du code v65 et porte les décisions du 10 novembre ; la version 4 y verse, telle quelle et à la demande de Lazar, la liste de la session mère « ce qui manque pour rassurer le jury sur l'approche peut marcher », qui porte sur le programme de contrôle (section 11). Les versions 2 à 4 n'ont pas été re-testées.

Comment lire ce document

Statuts : **préenregistré** écrit et scellé avant les données ; **à trancher** décision ouverte ; **choix** décision de conception ; **occupé** déjà publié par d'autres ; **fait** **en cours** **à faire** état d'un travail.

Qui est qui. Lazar dirige le programme ; c'est une personne. Les « sessions » sont des instances de Claude, chacune dans un rôle séparé : la *session mère* pilote le programme et lit ses résultats ; la *session de dépôt* tient le dépôt, les machines et les relais vers les fournisseurs de modèles ; la session *« attaquant informé »*, qui écrit ce document, conçoit le bras d'attaque (section 7) et ne lit aucun résultat d'attaque contre le juge de l'organisme, pour que ses propres épreuves de ce juge restent à connaissance déclarée. Un lecteur, un développeur ou un correcteur « neuf » est une instance sans mémoire du travail qu'il juge ; « d'une autre lignée » veut dire d'un autre modèle.

L'essentiel en une page

- **Ce que c'est.** Un petit système de recherche automatisée : des agents d'intelligence artificielle proposent des lois candidates (des « fiches »), et un **juge statistique**, calculé hors de tout agent, décide ce qui mérite d'être promu [N-064 ; RD].
- **L'idée centrale.** Le rôle qui produit ne tient jamais la clé qui évalue. Le juge travaille sur un engagement scellé avant que les données existent, contre un nul fait des lois déjà connues, avec un contrôle des comparaisons multiples. Il ne promeut que ce qui apporte au-delà de ce qu'on savait.
- **Comment on sait s'il marche.** Sur des mondes jouets dont on a planté les lois : un oracle compte les lois vraies retenues et les lois fausses promues. La composition des proposeurs se juge sur cet oracle et sur le coût, jamais sur le verdict du juge [N-058].
- **Sa place dans le programme de contrôle.** Le programme pose une seule question : *que mesure un moniteur, et sa mesure survit-elle à l'adversaire ?* Le juge de l'organisme est un moniteur, de prétentions de recherche ; l'attaquer relève de la même méthode que le bras d'attaque. Rôle adopté : second terrain du papier C [N-065].
- **La courbe dose-réponse.** Une seule existe, pour le juge seul et sans agent. Ce document propose celle de la chaîne complète, avec de vrais agents (section 6), à décider.
- **Où il en est.** Une première course de l'organisme sur le pilier « attaque » faite ; deux attaques contre le juge courues et lues ; la plus petite course réelle de la boucle entière attend son code et une machine adaptée. **Il est absent du texte envoyé au fonds** : à l'entretien, il se dit hors du plan financé.

1. Le problème que l'organisme attaque

La recherche automatisée confie à des agents la production d'idées et d'hypothèses. Le danger est connu : si un modèle juge les idées d'autres modèles, il peut être flatté, convaincu ou trompé, et des idées fausses passent pour neuves. C'est un cas de la loi de Goodhart : une mesure que l'on optimise cesse de mesurer.

L'organisme répond par une architecture. Les agents proposent ; aucun agent ne juge. Le jugement est une statistique, calculée par un programme (l'orchestrateur), sur des données tirées après que la proposition a été scellée, contre ce que l'on savait déjà. Cette idée n'est pas neuve en entier, et le projet le dit : POPPER calcule déjà des e-valeurs hors des agents ; Dwork et collègues (2015, réutilisation d'un

échantillon de validation sous analyse adaptative) et Blum et Hardt (« The Ladder », 2015, un tableau de classement qui résiste à qui lit ses scores) ont posé le principe : un juge dont on lit les verdicts peut être sur-ajusté, et l'on peut s'en garder ; Co-Scientist est voisin de la boucle « générer, classer, faire évoluer ». Ces quatre citations sont obligatoires dans tout texte qui présente l'organisme [N-064 point 4].

2. Un organisme, son objectif ultime, et une conception concurrente

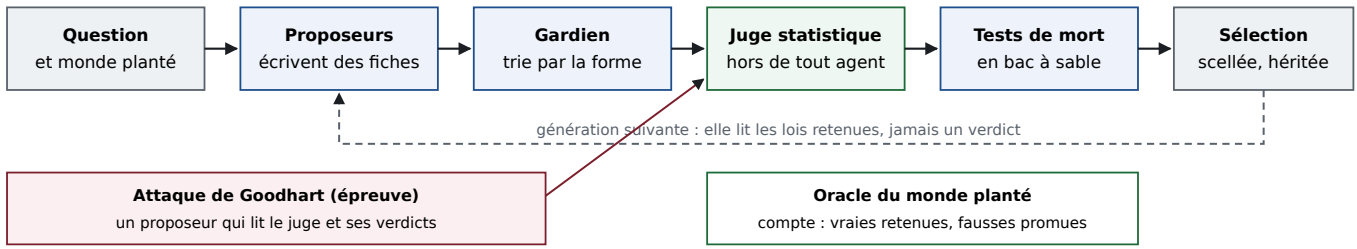
Lecture validée par Lazar le 10 novembre 2026 [DEC : R-2152], reprise telle quelle :

> « L'organisme d'idéation est l'organisme de l'objectif ultime (N-044, N-045), branché depuis le 28 octobre 2026 sur une tâche précise, proposer des hypothèses de recherche jugées par un juge statistique ; son code a continué sans rupture jusqu'aux versions 64 et 65. Il n'a pas encore les propriétés de l'objectif ultime : il ne se conçoit pas seul, rien n'est figé après une phase de conception, son universalité n'est mesurée sur aucune famille de questions jamais vue. La boucle fermée du code v65, où une génération hérite de la précédente, en est le premier pas. L'organisme de Gemini est une conception concurrente, rapportée à part. »

Ce que vise l'objectif ultime	Ce qu'il veut dire [N-044 ; N-045]
Se concevoir soi-même	Un système de plusieurs agents qui se réécrit sur un vivier de tâches à vérité connue, puis, son architecture figée, répond à des questions neuves sans réentraînement. Sa composition est apprise, modèle par rôle compris ; le coût entre dans le signal ; l'héritage entre générations est récompensé.
L'universalité	Mesurée sur des familles de questions jamais vues à la conception.
Où en est l'organisme d'idéation	Branché sur une seule tâche (proposer des hypothèses de recherche) ; la boucle fermée du code v65, où une génération hérite de la précédente, est le premier pas.

L'organisme de Gemini, conception concurrente, a été couru en pilotes du 24 au 26 octobre [GO] ; il est rapporté à part et n'est pas l'objet de ce document.

3. Comment il marche



La chaîne d'une génération, de la question à la sélection. L'oracle lit le monde planté, jamais le verdict du juge ; l'attaque de Goodhart est une épreuve du juge, pas une pièce de la chaîne. D'après le brouillon du préenregistrement de la boucle réelle [BR] et les décisions N-058, N-064.

Pièce	Ce qu'elle fait, et pourquoi
Proposeurs	Agents de fournisseurs différents (aujourd'hui Kimi et Argon). Ils écrivent des fiches : une fiche est une loi candidate, assez formelle pour être jugée. Ils ne voient jamais un verdict, et leur mémoire ne contient ni verdict ni témoin.
Gardien mécanique	Une « douane de forme » qui trie les fiches par leur seule forme ; les fiches trop concrètes vont à un coffre scellé. Aucun juge à modèle ne décide.
Juge statistique	Statistique calculée par l'orchestrateur, hors de tout agent, sur un engagement scellé avant que les données existent, contre un nul formé des lois connues (l'archive), avec un contrôle des comparaisons multiples [N-064].
Monde planté et oracle	Un monde jouet dont on connaît les lois : on y plante des lois vraies (à promouvoir) et des lois fausses (à refuser). Des témoins plantés sont mêlés anonymement à chaque génération ; des générations entières d'étalonnage ont un calendrier secret [N-059].

Tests de mort	Épreuves préenregistrées, exécutées en bac à sable par un expérimentateur et vérifiées par un agent d'une autre famille ; l'orchestrateur recalcule le verdict sur le fichier brut.
Sélection et héritage	La génération suivante lit le bilan scellé de la précédente, et refuse de partir sinon. Le signal porte sur plusieurs générations ; l'héritage est récompensé [N-045].
Composition et coût	Combien de parties, quels rôles, quel modèle par rôle : appris. Le coût entre dans le signal. Les voies bon marché passent avant les chères. La composition se juge sur l'oracle et le coût, jamais sur le verdict du juge [N-045 ; N-058].
Tâches fraîches, test final	Une part de tâches neuves tirée d'un vivier à chaque génération ; le test final n'est lu qu'une fois, en fin de boucle [N-049 ; N-050].

4. Un exemple suivi : une génération

1. **Le cadre.** Une question et un monde planté jouet (trois issues, deux traits). Une archive de départ déclarée et scellée : une loi connue. On plante quatre lois vraies et quatre lois fausses ; les fausses sont des recombinaisons de la loi connue, donc membres du nul [BR].
2. **Les propositions.** Deux proposeurs de fournisseurs différents écrivent douze fiches, six chacun, sans voir les lois plantées ni aucun verdict.
3. **Le jugement.** Le gardien trie par la forme. Le juge reçoit l'engagement scellé de chaque fiche, tire les données après le gel, calcule la statistique contre le nul des lois connues, corrige la multiplicité, et promeut ou non.
4. **Les tests de mort.** Les lois promues sont éprouvées en bac à sable ; l'orchestrateur recalcule le verdict sur le fichier brut ; la sélection est scellée.
5. **La génération 2** lit la sélection scellée (les lois retenues, jamais un verdict) et repart.
6. **L'oracle** compte les lois vraies retenues et les fausses promues. La prédiction de cette plus petite course, écrite au brouillon de son préenregistrement, **non encore scellé**, a le signe + : au moins une loi vraie promue puis survivante en génération 1, et aucune fausse promue en génération 1 ni 2 [BR].

5. Ses revendications, et ce qui est déjà publié

Statuts après la vérification d'antériorité et la décision N-064. « Non occupée » veut dire absente des pièces lues, pas « vierge » : une zone vierge est une question.

	Revendication	Statut
O1	le rôle qui produit ne tient jamais la clé qui évalue	voisine
O2	juge statistique : calculé par l'orchestrateur, engagement scellé, nul des lois connues, multiplicité	**occupée en partie** (POPPER) ; énoncé resserré
O3	prédictions scellées avant les données ; tirages semés par l'empreinte	voisine
O4	battre un nul des lois connues : « rien au-delà de l'archive »	non occupée
O6	douane de forme, coffre scellé	voisine
O8	proposeurs de plusieurs fournisseurs	non occupée
O10	témoins plantés vrais et faux à chaque génération	voisine
O11	banc de tricheurs scriptés	**occupée dans son principe** (Dwork et collègues ; Blum et Hardt) ; la forme seule est revendiquée
O12	attaque de Goodhart : un proposeur qui lit la description du juge et, dans un bras, ses verdicts, sur des mondes où toute promotion est fausse	**occupée dans son principe** ; la forme non trouvée
O13, O14	tests de mort en bac à sable ; sélection entre générations par ces tests	voisines
O17	scellement avant lecture ; aucun repli silencieux	non occupée
O19	puissance du juge mesurée : « rien promu » n'est pas « aucun effet »	voisine
O20	juge éprouvé sur une vérité plantée	occupée dans son principe (pratique courante)

Liste abrégée (O1 à O20 en entier dans la note d'antériorité [ACS]). Les revendications O sont des choix de conception, sans signe ; les signes vivent dans les préenregistrements : l'attaque de Goodhart A1-v4 (hypothèses H1 à H5, prédictions P1 à P11, « ouvertes dans les deux sens ») et la boucle réelle (prédiction P1, signe +) [A1P ; BR]. La page publique du projet ne cite pas encore les quatre références obligatoires ; la corriger est une publication, donc un geste de Lazar.

6. La courbe dose-réponse

Pourquoi elle compte. Dans le programme de contrôle, la courbe dose-réponse des organismes de sabotage valide l'instrument : si le réglage de la dose n'agit pas, rien de ce que lisent les moniteurs ne se conclut. L'équivalent, pour l'organisme, est la courbe qui montre que la chaîne réagit au signal : plus une loi vraie est forte dans le monde, plus elle doit être retrouvée et promue ; et les fausses ne doivent jamais l'être, à aucune dose. Sans elle, un « rien promu » ou un « tout promu » ne se lit pas.

Ce qui existe : l'épreuve « W2 graduée » scellée

La dose λ est le poids d'une loi nouvelle ajoutée à un monde qui, à λ = 0, n'apporte rien au-delà de l'archive. Grille gelée de onze doses (0 ; 0,05 ; 0,10 ; 0,15 ; 0,20 ; 0,25 ; 0,30 ; 0,40 ; 0,50 ; 0,75 ; 1), la dose 0 jouée comme contrôle ; mille répétitions par dose. Deux réponses : la fréquence de promotion de la loi du monde, et celle de la recombinaison pure, qui doit rester nulle. Règle écrite avant l'épreuve : la dose retenue est la plus petite où la loi du monde est promue au moins 800 fois sur 1 000, et la recombinaison jamais [W2G]. **Limite** : c'est une courbe du juge seul, hors ligne, sans agent ; elle n'a servi qu'à fixer la dose d'une épreuve.

Ce qui manque, et ce que je propose

> **Décision** : ajouter à l'organisme la courbe dose-réponse de la chaîne complète, avec de vrais agents. **Enjeu** : valider l'instrument entier, comme le critère 2 de la porte de fin de phase le fait pour le programme ; tu as demandé cette courbe le 10 novembre.
>
> - **(a) Courbe de sensibilité.** Dose : la force de la loi vraie d'un monde d'étalonnage au-delà de l'archive (par exemple le poids λ d'une loi nouvelle, comme dans l'épreuve W2 graduée) ; la famille de mondes exacte se fixe au préenregistrement. Réponses lues sur l'oracle : la probabilité qu'une loi vraie soit promue puis survive aux tests de mort, et le taux de fausses promotions. Grille gelée, répétitions dimensionnées par simulation, contrôle à λ = 0, critère de croissance et seuil, le tout préenregistré. Avantage : valide la chaîne entière et prolonge une épreuve déjà scellée. Inconvénient : coûteuse (agents × doses × répétitions), donc devis.
> - **(b) Courbe de corruption.** Dose : la pression adverse (nombre de verdicts que l'attaquant peut lire, ou part de proposeurs tricheurs). Réponse : le taux de fausses promotions. Avantage : c'est la courbe du bras d'attaque appliquée au juge, au cœur du papier C. Inconvénient : elle touche au pilier « attaque » de l'organisme et suit les règles du bras.
> - **(c) Les deux, à la suite.**
>
> **Recommandation** : (a) d'abord, sur cinq doses (0 ; 0,10 ; 0,25 ; 0,50 ; 1), dès que la plus petite course réelle de la boucle tourne ; (b) ensuite, dans le cadre du bras. Confiance 0,6. C'est une dépense : préenregistrement, devis, autorisation, puis ton mot.

Quand peut-elle partir ?

Pas avant la plus petite course réelle de la boucle : la chaîne complète n'a encore jamais tourné avec de vrais agents. Cette course attend trois pièces [BR, section 12]. D'abord le code v65 : son premier développeur a été arrêté par Lazar le 8 novembre et son travail tenu pour annulé [DEC : R-1767] ; le développement reprend dans une session neuve (mot de Lazar du 10 novembre, relayé par la session mère). Ensuite une machine jetable dotée du bac à sable bubblewrap, à louer quand le code v65 sera contre-lu. Enfin les commandes des relais des deux fournisseurs, versées le 10 novembre par la session de dépôt avec la configuration v5 [RL]. Une course coûte environ 2 à 8 dollars attendus, 35 au pire [BR, section 13] ; une courbe de cinq doses sur huit mondes en demande quarante, soit de l'ordre de 80 à 320 dollars attendus, à fixer au devis. Son préenregistrement peut s'écrire dès maintenant, sur le dessin de cette course.

7. Sa place dans le programme de contrôle

> **Le programme de contrôle, en bref.** Un *moniteur* surveille un agent d'intelligence artificielle et alerte s'il soupçonne un sabotage ; une *sonde* est un moniteur qui lit les activations internes du modèle, au lieu

> de ses seuls textes. Le programme a trois papiers : **A**, le sabotage étalé dans le temps sur de nombreuses actions (sa porte de décision s'appelle G1) ; **B**, le sabotage réparti entre plusieurs agents ; **C**, l'adversaire qui agit sur le moniteur lui-même (flatterie, persuasion, usurpation), mesuré sur des juges et des sondes. Le **bras d'attaque** éprouve les moniteurs gelés contre un attaquant dont la connaissance est déclarée, échelon par échelon : 0, pression déclarée ; 1, aveugle ; 2, informé de la conception, par le seul contenu de ses actions ; 3, informé, avec un nombre compté de verdicts du moniteur ; 4, écriture des activations ; 5, réglage fin des poids ; 6, renforcement contre la sonde. Une **famille tenue à l'écart** est une famille de sabotages écrite sans voir aucun moniteur et réservée pour mesurer si un moniteur tient sur ce qu'il n'a jamais vu.

Une seule question. Le programme de contrôle demande : *que mesure un moniteur, et sa mesure survit-elle à l'adversaire ?* Le juge de l'organisme est un moniteur, de prétentions de recherche au lieu d'actions d'agent. La même question s'y pose, avec les mêmes outils : moniteur gelé, adversaire de connaissance déclarée, lecture scellée.

Rôle (décision N-065)	État	Ce qu'il apporte au programme
1. Second terrain du papier C	adopté	La corruptibilité de deux sortes de juges : le juge statistique (attaque de Goodhart) et un juge génératif en tournoi, façon Co-Scientist (conçu, non lancé).
2. Atelier d'idées	adopté	Des idées pour le programme ; une fiche est un matériau, jamais une preuve ; tout usage décisif passe par un préenregistrement.
3. Famille de menaces diffuses	à trancher	Un proposeur à poids ouverts qui trompe le juge sur de nombreuses propositions d'apparence honnête est une menace diffuse au sens du programme ; s'il devient famille tenue à l'écart, il doit être écrit sans voir aucun moniteur.

- **Invariants.** Aucun score d'un moniteur du programme n'entre dans l'entraînement ni la sélection de l'organisme [N-053 point 5, rappelé par N-065] ; la sélection des proposeurs ne lit jamais le verdict du juge [N-058].
- **Lien avec le bras d'attaque.** L'attaque de Goodhart est un attaquant qui lit les verdicts d'un juge gelé, à budget compté : la structure de l'échelon 3 du bras, appliquée au juge de l'organisme. La courbe (b) de la section 6 est sa courbe d'évasion.
- **Un monde tiré du programme.** L'orchestrateur prévoit un « monde sur banque » dont les instances viennent des épisodes du programme, issues cachées [C7].
- **À l'entretien** : une diapositive, hors du plan financé ; aucun chiffre de l'attaque hors de ce que fixe son verdict scellé (section 9) ; jamais « universel » ; les quatre citations obligatoires [RD].

8. Ce qui a été fait, au 10 novembre 2026

Chantier	État	Pièce, date
Pilotes de l'organisme de Gemini (conception concurrente, rapportée à part)	faits	24-26 octobre ; plusieurs courses [GO]
Organisme du pilier « attaque », version 1	couru	30 fiches validées ; autorisation close à 8,42 dollars sur un plafond de 20 (GO-2026-11-08-08) ; fiches au coffre [DEC : R-1853, R-1885]
Attaques de Goodhart A1-v3 et A1-v4	courues, lues	préenregistrement scellé [A1P] ; verdicts officiels scellés, celui d'A1-v4 par un lecteur neuf d'une autre lignée que l'auditeur [DEC : R-2111] (section 9)
Épreuve « W2 graduée »	scellée	courbe du juge seul (section 6) [W2G]
Essai à blanc de la boucle complète	fait	deux générations, fournisseurs simulés [BR]
Plus petite course réelle de la boucle	en attente	préenregistrement en brouillon [BR] ; autorisation de 45 dollars jusqu'au 30 novembre (GO-2026-11-08-02) ; manquent le code v65 (développement repris en session neuve) et une machine qui isole les épreuves ; les commandes des relais sont versées [RL]

Juge en tournoi, façon Co-Scientist	conçu	non lancé ; devis de 80 à 145 dollars [RD]
Présence dans le texte envoyé au fonds	absent	à dire hors du plan financé

9. Résultats — section réservée à la session mère

L'auteur de ce document ne lit aucun résultat d'attaque contre le juge de l'organisme ni aucun résultat de moniteur du programme. Cette section est à compléter par la session mère, depuis les pièces scellées : les verdicts des attaques A1-v3 et A1-v4, dans leur lecture bornée ; l'issue de l'épreuve W2 graduée ; ce que l'essai à blanc a montré ; et ce qui sera lu avant l'entretien.

10. Les décisions qui t'attendent sur l'organisme

Décision	Où elle en est
Courbe dose-réponse de la chaîne complète (section 6)	go de Lazar le 10 novembre : (a) d'abord ; préenregistrement en brouillon [CB] ; lancement après la plus petite course, sur devis et autorisation ; plafond à décider au devis
Accès au code de l'organisme pour la simulation sans agents qui dimensionne la courbe	décidé le 10 novembre : copie empreintée du seul code nécessaire, au commit 94bfd92, sans résultat ni code d'attaque, versée par la session de dépôt [D1050]
Chemin critique de la courbe : code v65, machine avec bubblewrap, commandes des relais	le code v65 reprend en session neuve, dates à venir ; les relais sont versés [RL] ; la machine sera louée quand le code sera contre-lu, fournisseur à fixer
Rôle 3 : famille de menaces diffuses, tenue à l'écart ou non	à trancher avant toute conception de sonde qui pourrait la toucher (session mère, confiance 0,5) [RD]
Juge du tournoi : Kimi, ou un modèle Claude sur crédits	ouvert [RD]
Règle de permission de la course v2	accordée pour une seule commande
Prix du nul v9 ; question de sens de W2	ouverts depuis le 8 novembre
Régimes de budget et code figé (étape 1 de N-044)	en attente de ton mot
Correction de la page publique (quatre citations)	une publication, donc ton geste
Lien entre l'organisme et l'organisme de l'objectif ultime	tranché le 10 novembre : lecture validée par Lazar (section 2) [DEC : R-2152]

11. Ce qui manque pour rassurer le jury sur « l'approche peut marcher » — v1

Liste de la session mère, insérée telle quelle à la demande de Lazar (10 novembre 2026) ; source et empreinte en annexe [CQM].

État relevé le 10 novembre 2026 à 10:46 UTC (`date -u`), session mère. Entretien visé le 27 novembre 2026, à confirmer avec le fonds. Cette liste ne porte aucun résultat de surveillant ni de sonde : seulement ce qui doit exister, sa date et son état. Elle est à insérer telle quelle dans chaque document qui explique le programme.

Ce qui est dit d'abord au jury : aucune sonde n'a encore battu un surveillant de référence, et l'existence d'une trace interne du sabotage n'est pas établie. Le programme ne peut pas promettre une réponse positive ; il traite la question par des expériences préenregistrées dont l'issue est écrite d'avance dans les deux sens.

Priorités fixées par Lazar le 10 novembre : d'abord la ligne 5, puis les lignes 4, 7 et 8.

n°	Ce qui manque	Pourquoi le jury le demandera	Avant le 27 novembre ?	État au 10 novembre
1	La chaîne de sondes retrouve un signal planté, et se tait sur son jumeau honnête (témoin positif).	Sans cela, un résultat nul ne dit rien : la chaîne pourrait être aveugle.	Oui : lu le 20 novembre au plus tard.	Texte au brouillon 11 ; code validé par une contre-lecture ; course à créer au plus tard le 18.
2	Un saboteur sans consigne, dont l'effet sur le coût croît avec la dose (course de confirmation).	Le seul saboteur existant recevait une consigne, que la sonde lisait.	Oui : verdict du 16 au 18.	Texte scellé ; course à créer au plus tard le 15.
3	À ces doses, le texte seul ne suffit pas à repérer le sabotage (surveillants externes de référence).	Si lire le texte suffit, lire l'intérieur n'apporte rien.	Possible : vers le 20 ou le 21.	Premier brouillon du texte en rédaction.
4	Une sonde au-dessus du hasard à ces doses.	C'est la première preuve que la trace existe.	Possible, sans marge ; dépend des lignes 1 à 3 et du scellement du texte des sondes.	Texte des sondes au brouillon 21 ; scellement visé avant le 13.
5	La sonde lit le sabotage, et non le simple fait qu'un adaptateur est actif.	Le saboteur sans consigne est un adaptateur ajouté aux poids ; l'honnête est le modèle nu. Une sonde pourrait ne lire que cette différence.	À établir en premier.	Aucun témoin « adaptateur honnête » trouvé dans le texte scellé de la course (recherche par mots, vérification sur texte en cours) ; remèdes à l'étude : contraste au sein d'une même dose, témoin distillé honnête.
6	La puissance de cette lecture, écrite avant de lire.	Un résultat nul doit dire quel effet il exclut.	Oui.	À vérifier dans le texte des sondes.
7	Un résultat positif déjà publié, reproduit sur notre chaîne (banc public).	Preuve, hors de nous, que la chaîne sait voir ce que d'autres ont vu.	Possible.	Texte au brouillon 4, contre-lu trois fois ; code à écrire ; dépense à autoriser sur devis.
8	Un sabotage vraiment diffus : chaque action dans la plage honnête, le dommage dans l'ensemble seulement (saboteur à budget).	Le saboteur actuel peut être flagrant ; la thèse porte sur le diffus.	Incertain ; exploratoire.	Conçu et contre-lu une fois ; code à écrire ; dépense à autoriser sur devis.
9	Des témoins de concepts : la sonde ne réagit pas à un sujet quelconque.	Contrôle de validité.	Incertain.	Deux concepts sur quatre acceptés, deux refusés deux fois ; nouvelle consigne en rédaction ; le texte des sondes prévoit un repli sans eux.

10	Le jeu d'entraînement de la sonde du domaine « coût gonflé ».	Sonde la plus proche du sabotage étudié.	Incertain.	Refusé pour un indice de surface ; une dernière réécriture est permise.
11	La preuve datée, chez un tiers, que chaque préenregistrement précède ses données.	Seule vérification possible sans nous.	Oui.	Empreintes déposées en privé ; à rendre public et à geler.

Sources : `registres/decisions.md`, R-2116 à R-2162 ; `brouillons/entretien-taif-v3/socle-preuves-entretien-v2.md`.

Clé des noms

Nom	Ce qu'il désigne
A1, A1-v3, A1-v4	L'attaque de Goodhart contre le juge statistique, dans sa troisième et sa quatrième version.
W1, W2, « W2 graduée »	Des mondes de l'attaque A1 ; « W2 graduée » est l'épreuve à dose de la section 6. La « question de sens de W2 » est une question ouverte de Lazar sur ce que ce monde mesure.
Nul v8, nul v9	Deux versions du nul des lois connues ; v8 est en production ; v9 couvre une classe de recombinaisons de plus et a été éprouvé à part ; son « prix » est une décision ouverte sur son coût.
Code v65	La version de l'orchestrateur qui manque à la plus petite course réelle de la boucle ; elle ferme la boucle, une génération héritant de la précédente.
Pilier « attaque », course v2	L'organisme appliqué à une question scellée sur les attaques contre les moniteurs ; ses fiches vont au coffre, en quarantaine. La « course v2 » est sa course sur la version 2 de cette question.
Numéros dans les chemins	« reprise-v9 », « goodhart-v5 », « orchestrateur-v52b » : des versions de travail des dossiers et des textes ; seule l'empreinte identifie une pièce.

Annexe — Sources

Sigle	Pièce	Empreinte
N-044	`docs/decisions/decision-N-044-v1.md`	`2b70bdac…`
N-045	`docs/decisions/decision-N-045-v2.md`	`c7b05e39…`
N-049	`docs/decisions/decision-N-049-v1.md`	`8a5bf5e5…`
N-050	`docs/decisions/decision-N-050-v1.md`	`a54b128d…`
N-053	`docs/decisions/decision-N-053-v1.md`	`2204256d…`
N-058	`docs/decisions/decision-N-058-v1.md`	`854f2724…`
N-059	`docs/decisions/decision-N-059-v1.md`	`41aff854…`
N-064	`docs/decisions/decision-N-064-v1.md`	`387c9d4e…`
N-065	`docs/decisions/decision-N-065-v1.md`	`f820e90d…`
[RD]	rapport de la session mère du 9 novembre, section 6, `docs/notes/rapports-directeur/rapport-principes-etat-goulots-entretien-organisme-2026-11-09-v1.md`	`22263fce…`
[ACS]	note d'antériorité, `docs/notes/ideation-organisme-v1/anteriorite-co-scientist-v1/note-anteriorite-co-scientist-v1.md`	`08a3738a…`
[APE]	note sur POPPER, `docs/notes/ideation-organisme-v1/anteriorite-co-scientist-v1/note-anteriorite-popper-evaluator-v1.md`	`d1ab7049…`
[BR]	boucle réelle, brouillon non scellé, `docs/notes/organisme-boucle-reelle-v1/preenregistrement-boucle-reelle-organisme-v1-brouillon1.md`	`736e3fd6…`
[W2G]	épreuve W2 graduée, `docs/notes/ideation-organisme-v1/a1-v4-reprise-v9/epreuve-w2g-dose-v2-v1.md`	`e025f108…`
[A1P]	préenregistrement de l'attaque A1-v4, `docs/notes/ideation-organisme-v1/a1-v4-reprise-v9/preenregistrement-attaque-goodhart-v5-v1.md`	`d306a8fa…`
[C7]	conception de l'orchestrateur, `docs/notes/ideation-organisme-v1/orchestrateur-v52b/conception-v7-v1.md`	`31fc8c4b…`
[GO]	registre des autorisations, sur main au 10 novembre (lignes GO-2026-11-08-02 et -08 ; pilotes, lignes 47 à 73), `registres/go.md`	`e682abb0…`
[DEC]	registre des décisions, sur main au commit 05995a4a, 10 novembre (R-1767, R-1853, R-1885, R-2111, R-2152), `registres/decisions.md`	`b12604ac…`
[RL]	commandes des relais et configuration v5, versées par la session de dépôt (branche claude/upbeat-cray-dmauvv, commit 9dce5742) : `registres/passations/2026-11-10-1045-organisme-m6-commandes-et-configuration-v5.md` ; configuration `docs/notes/ideation-organisme-v1/tour-ferme-etage1-v1/configuration-tour-ferme-v5.json` (995eb918…)	`abf72390…`
[CQM]	liste « ce qui manque pour rassurer le jury », session mère, sur main au commit 983dd664, `docs/notes/rapports-directeur/ce-qui-manque-approche-peut-marcher-v1.md`	`edb0bf03d87dd208…`
[CB]	préenregistrement de la courbe de la chaîne complète, brouillon 1, `docs/notes/organisme-courbe-dose-reponse-v1/preenregistrement-courbe-chaine-complete-v1-brouillon1.md`	`a0fe0114…`
[D1050]	décision de Lazar « go recos » du 10 novembre, `registres/passations/2026-11-10-1050-decision-lazar-go-recos-acces-hc2-licence.md`	`def13a65…`
—	questionnaire de compréhension, scellé avant ce document, `docs/notes/entretien-recapitulatif-v1/questionnaire-comprehension-organisme-v1.md`	`66deeea0…`