VERSION VULGARISÉE · PROGRAMME PRÉPARÉ POUR L'ENTRETIEN DE FINANCEMENT

Savoir d'avance ce qu'un surveillant ne peut pas voir

Ce que nous demandons au Transformative AI Fund, pourquoi, ce qui est déjà en main, ce qui ne l'est pas encore, ce qui s'est ajouté depuis la candidature, et les questions difficiles auxquelles il faut s'attendre.

L'entretien, d'abord prévu le vendredi 30 octobre 2026, est décalé à la demande de Lazar ; la nouvelle date reste à fixer. Il a demandé ce délai pour finir le nouveau programme et présenter des résultats préliminaires et les questions nouvelles. Ces résultats seront présentés quel qu'en soit le signe : aucune expérience n'est conçue pour obtenir un résultat favorable.

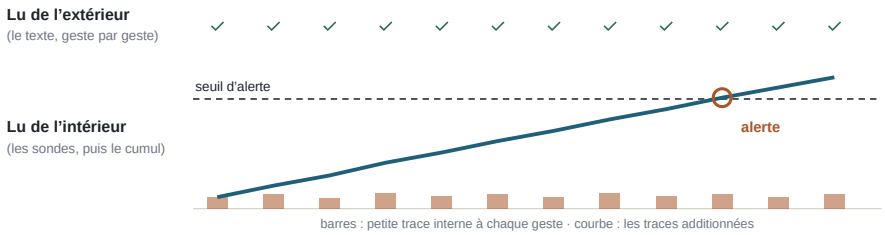
Version 2 du document vulgarisé, écrite le 29 octobre 2026 pour un lecteur non spécialiste. Elle vulgarise la version 15 du programme préparé pour l'entretien et sa version condensée pour trente minutes (version 2). **Ces deux textes ne font foi qu'après le mot de Lazar**, le directeur du programme ; la version 15 n'a pas encore été relue par un relecteur indépendant. Ce document n'avance que ce que ces textes disent avec leur source ; ce qui est ouvert est marqué QUESTION OUVERTE ; ce qui attend le mot de Lazar est marqué À VALIDER. Les chiffres sont arrondis ; rien ici n'ajoute de résultat ; tout ce qui n'est pas encore fait est écrit au futur.

1 Ce que nous demandons, et pourquoi — en une page

Les intelligences artificielles ne se contentent plus de répondre à une question. On leur confie des tâches longues, qu'elles mènent seules : écrire du code, préparer une expérience scientifique. On les appelle des **agents**. Pour les surveiller, on place à côté d'eux un **moniteur** : un surveillant automatique qui lit ce qu'ils produisent et donne l'alerte quand quelque chose cloche.

Le cas difficile est la **menace diffuse** : un mauvais comportement découpé en dizaines de petits gestes, dont aucun n'est alarmant pris seul. Comme un comptable qui détournerait quelques centimes sur des milliers de lignes : chaque ligne paraît juste, c'est l'addition qui est fausse. Un surveillant qui lit seulement le texte, geste par geste, est mal placé pour le voir.

Notre pari : **regarder à l'intérieur**. Pendant qu'il travaille, un modèle d'intelligence artificielle calcule des milliers de nombres à chaque mot. De petits détecteurs, les **sondes**, peuvent lire cette activité interne. Même si chaque geste paraît innocent à l'extérieur, il pourrait laisser une petite trace à l'intérieur — et ces traces, elles, peuvent **s'additionner** dans le temps.



L'idée de départ, en image. Ce n'est encore qu'une hypothèse : le programme existe pour savoir si elle est vraie sur de vrais modèles, et surtout **à quelles conditions elle ne l'est pas**.

LE PROGRAMME, EN TROIS PHRASES

Les surveillants d'agents automatiques sont jugés sur les attaques que quelqu'un a su imaginer, et personne ne peut dire d'avance ce qu'un surveillant donné est incapable de voir. Nous construisons cette réponse : pour chaque règle de calcul qu'applique un surveillant, ce qu'elle suppose sur l'agent et ce qui la rend aveugle ; nous la vérifierons sur des données déjà payées et l'éprouverons contre un adversaire gouverné. Nous rapportons nos échecs avec ce qu'ils excluent, nous gelons nos examens de passage d'avance, et le tout a coûté quelques centaines de dollars.

LA DEMANDE, EN TROIS PALIERS

La candidature envoyée le 7 octobre demande **58 630 dollars** pour sept mois. La même candidature décrivait déjà un scénario ambitieux à **138 600 dollars** sur douze mois. Nous présentons un troisième palier qui ajoute ce que le programme a gagné depuis : environ **38 000 dollars** d'extension, nommée et chiffrée ligne par ligne (partie 7). Si Lazar confirme que l'extension s'ajoute au scénario ambitieux, le troisième palier vaut **176 550 dollars** ; sinon, c'est le plancher plus l'extension, environ **86 130**. L'argent finance surtout du **temps de recherche**, très peu de calcul. À VALIDER

2 Ce qui a changé d'ambition

La candidature présentait trois articles de recherche sur les menaces diffuses, appuyés sur un résultat mathématique général. Depuis le 28 octobre, le programme se présente plus haut : comme une **théorie des angles morts des surveillants**. La question n'est plus seulement « nos sondes marchent-elles ? », mais : **pour chaque surveillant, dans quelles conditions mesurables est-il aveugle, preuve à l'appui — et lequel reste debout quand plusieurs conditions s'additionnent ?**

L'image est celle d'une **notice**. Un appareil de mesure sérieux est vendu avec ses limites : « ne mesure pas sous zéro degré ». Personne ne fournit aujourd'hui cette notice pour les surveillants d'intelligence artificielle. Nous voulons l'écrire, d'avance et avec des démonstrations. La phrase prévue pour l'entretien le dit ainsi : *nous construisons la partie du contrôle de l'intelligence artificielle qui vous dit, d'avance et preuve à l'appui, ce que votre surveillant ne peut pas voir.*

Le programme n'est pas borné par les deux questions envoyées

La candidature posait deux questions étroites, choisies parce qu'elles étaient finançables et démontrables en sept mois. Elles restent vraies et restent au programme. Mais elles ne le bornent pas : le périmètre bouge quand un outil nouveau le permet. Ce n'est pas de l'opportunisme, parce que trois freins restent en place :

1. **Une porte ne bouge pas.** Les critères de l'examen de passage de fin novembre sont gelés depuis le 5 octobre. Élargir le périmètre n'en dispense pas.
2. **Un engagement écrit ne se réécrit pas.** Toute question nouvelle entrera par un document neuf, figé avant l'expérience et relu par quelqu'un qui ne l'a pas écrit.
3. **Une revendication ne s'étend pas sans décision** du directeur ; les agents travaillent sous des règles qu'ils ne relâchent pas seuls.

Devant le fonds, cela veut dire : nous ne demandons pas de financer deux questions, mais une **capacité à poser les bonnes**, avec des freins qui empêchent que ce soit un chèque en blanc. Si le fonds ne veut financer que le plancher, le plancher est tenu tel qu'il a été envoyé.

L'« organisme » qui cherche lui-même des idées

Le second changement s'appelle l'**organisme** : un ensemble d'intelligences artificielles qui proposent des idées, les mettent à l'épreuve et gardent les meilleures, génération après génération — un petit laboratoire automatique, tenu par des règles et des plafonds de dépense. Sans lui, on teste les sabotages qu'un humain a su imaginer, sur les tâches qu'un humain a su écrire. Avec lui, on pourra poser des questions d'une autre taille, par exemple : un détecteur marche-t-il sur des familles de tâches **jamais vues** pendant sa conception ? C'est la différence entre un résultat et une loi.

Il y a une ironie voulue : dans la version la plus ambitieuse, l'agent que l'on surveille est lui-même un **chercheur automatique**. Concevoir l'organisme devient donc une question de recherche en soi.

3 Ce qui s'est ajouté depuis la candidature, et pourquoi le programme demande plus

La candidature a été déposée le 7 octobre. Trois semaines plus tard, le programme ne décrit plus le même objet. Le tableau ci-dessous met en regard, point par point, ce que disait la candidature et ce qui existe ou a été décidé depuis ; la dernière colonne dit ce que cela coûte : du temps de recherche, ou une ligne de l'extension chiffrée (partie 7). La comparaison est faite avec les versions de la candidature conservées au dépôt ; les montants envoyés sont repris de la ventilation de la demande. Tout ce qui n'est pas encore fait est au futur.

OBJET	CE QUE DISAIT LA CANDIDATURE (7 OCTOBRE)	CE QUI EXISTE OU EST DÉCIDÉ DEPUIS	POURQUOI C'EST PLUS AMBITIEUX	CE QUE CELA COÛTE
La théorie	Un résultat d'addition et un théorème négatif, portant sur une famille de règles de calcul	Une **carte** de ce que chaque surveillant suppose sur l'agent et de l'écart qui l'aveugle (28 octobre) ; sa vérification par un logiciel de preuve est **proposée, pas décidée**	On passe d'un résultat général à une notice, hypothèse par hypothèse	Ligne « théorie et preuves », 5 000 ; surtout du temps
Des mesures sans calcul neuf	Absent	Six mesures prévues sur des données déjà payées, chacune à figer avant lecture	La théorie se testera sans dépenser	Du temps, pas de calcul
L'adversaire	« Attaques adaptatives », y compris en réentraînant contre la sonde	Un type de sabotage conçu à part, par une instance qui n'a conçu aucun surveillant, scellé avant la porte (26 au 28 octobre) ; toute chaîne offensive **gelée** jusqu'à une revue de sécurité extérieure, encore à commander	Des attaques inédites pour ceux qui conçoivent les surveillants, sous une porte intérieure	Revue extérieure, 7 500 ; adversaire scellé, 4 000
Le chercheur automatique	Absent : les agents exécutaient	L'organisme, décidé du 24 au 28 octobre ; des pilotes (environ 160 dollars) et deux lancements réels (environ 12 dollars) ; la première course d'idées lancée le 29 (partie 4)	L'adversaire et l'instrument deviennent un chercheur automatique, lui-même mesuré	L'organisme, 12 000
L'universalité	Refaire les surveillants sur une seconde famille de modèles (déjà au scénario ambitieux)	L'organisme sera jugé sur des familles de tâches jamais vues à la conception, avec des tâches fraîches à chaque génération	Une seconde question d'universalité, sur l'organisme lui-même	Même ligne ; du temps

OBJET	CE QUE DISAIT LA CANDIDATURE (7 OCTOBRE)	CE QUI EXISTE OU EST DÉCIDÉ DEPUIS	POURQUOI C'EST PLUS AMBITIEUX	CE QUE CELA COÛTE
Le collisionneur	Absent	Depuis le 24 octobre : trois familles de modèles conçoivent, attaquent et corrigent les surveillants ; quelques centaines de dollars au registre	Une méthode de conception à trois voix, et non un seul modèle	Le collisionneur, 6 000
Savoir si le sabotage a nui	Une vérité « semée » d'avance, et une validation humaine	Décision du 29 octobre : le dommage sera mesuré sans les surveillants, par des lecteurs d'autres familles de modèles, contre une référence cachée	Un dommage mesuré indépendamment de ceux qu'on évalue	Du temps ; calcul couvert par les lignes envoyées
La porte interne	Battre le meilleur surveillant qui ne lit que le texte	Battre aussi deux comparateurs qui lisent l'intérieur et un juge textuel à qui l'on a décrit la menace ; sans gagner par plus de fausses alertes ; type de sabotage par type (26 au 29 octobre)	Une porte plus dure, scellée avant toute lecture	Du temps ; calcul couvert par les lignes envoyées
La délégation	Absent	Une question ajoutée le 22 octobre : un agent qui délègue transmet-il ses consignes de sécurité ? (sous réserve qu'elle ne soit pas déjà traitée ailleurs)	Une question de plus pour l'article sur l'essaim	Du temps
Les instruments vérifiés	Présent pour l'outil de lecture interne (refait à l'identique)	Étendu aux sondes du premier test, aux juges automatiques et aux « lentilles » qui lisent les sondes	Chaque instrument mesuré avant usage	Environ 4 dollars consignés ; un rejeu en cours sous 5
Grand modèle, seconde famille, attaques par renforcement	Au scénario ambitieux envoyé	Inchangé	Rien d'ajouté	Scénario envoyé, 138 600

Pourquoi c'est bien plus ambitieux. La candidature proposait trois articles sur les menaces diffuses, avec un résultat mathématique général. Le programme se présente désormais comme une théorie de ce que les surveillants ne peuvent pas voir : pour chaque règle de calcul, ce qu'elle suppose sur l'agent et ce qui la rend aveugle ; **à vérifier** sur des données réelles déjà payées ; **à éprouver** contre un adversaire gouverné, qui comprendra des sabotages inédits scellés avant la porte ; et **à porter** par un dispositif qui pose lui-même ses questions, jugé sur des familles de tâches qu'il n'aura jamais vues. Les trois articles restent le cœur de ce qui est livré ; au palier plancher, seuls deux sont financés. Rien n'est relâché : les critères de la première porte sont gelés ; toute question nouvelle entrera par un plan scellé et relu par un agent neuf avant toute lecture ; toute revendication nouvelle est décidée par le directeur.

Ce que l'enveloppe supplémentaire paie. Le formulaire porte 58 630 dollars. L'extension — revue de sécurité extérieure, adversaire scellé exécuté seulement après cette revue, théorie et preuves (vérification par machine proposée), organisme, collisionneur, réserve de dix pour cent — fait environ 38 000 dollars. **Si Lazar confirme** qu'elle s'ajoute au scénario ambitieux, la version la plus ambitieuse vaut 176 550 dollars ; **sinon**, c'est le plancher plus l'extension, environ 86 130. Le reste du tableau coûte surtout du

temps ; le calcul qu'il entraîne tient dans les lignes déjà envoyées. Ce sont des ordres de grandeur, pas des devis. À VALIDER

4 Ce qui est en main aujourd'hui, et vérifiable

Tout ce qui suit est consigné dans les registres du programme, avec une empreinte numérique (une sorte de code-barres qui change si un seul caractère du fichier change). Les déceptions sont mises **au même rang** que les avancées : un programme qui ne montre que ses succès ne mérite pas qu'on le croie.

AVANCÉES

- Une théorie testée en simulation, prédictions écrites d'avance : **31 sur 31** tenues. Simulation, pas données réelles.
- L'outil qui lit l'activité interne **validé sur un vrai modèle** de huit milliards de paramètres (premier critère de la porte de novembre). Il valide l'instrument, pas une détection.
- Un banc d'essai de sabotage de recherche **reconstruit** d'après un article publié sans code ni données ; 180 épisodes d'un vrai agent enregistrés et scellés.
- Environ 3 500 citations contrôlées, aucun échec ; environ 900 tests automatiques.

NOUVEAU

- La **carte des angles morts** (28 octobre) : pour chaque surveillant, ce qu'il suppose sur l'agent et l'écart qui l'aveugle. Elle existe, elle est datée ; son contenu ne se transmet pas.
- Une **boucle automatique** de test d'hypothèses, qui a tourné de bout en bout sur des données réelles.
- Les détecteurs **refaits à l'identique** : 424 sur 424, au dernier chiffre près.

DÉCEPTIONS

- Le premier vrai test intérieur est **revenu nul**.
- Nos **juges automatiques** ne notent pas toutes les copies.
- Notre **garde-fou statistique** est presque muet à petite taille.
- Un incident d'agents le **23 octobre**, et des refus de modèles.

CE QUI TOURNE AUJOURD'HUI, 29 OCTOBRE — SANS AUCUN CHIFFRE, PARCE QU'AUCUN N'EST LU

- **La première course d'idées de l'organisme** a été lancée à 10 h 36 (temps universel), sous une enveloppe d'une soixantaine de dollars, après dix relectures de son programme de pilotage et une épreuve réelle courte. Sa sortie n'est pas lue : devant le fonds, on dit « lancée, sortie pas encore lue », jamais « elle produit des idées ».
- **Le second examen des juges automatiques** (partie « déceptions », bloc 2) a été lancé le 29, sous 4 dollars au plus ; aucun chiffre avant sa lecture gelée.
- **Le collisionneur a débattu de la règle de repli** de la porte de novembre (partie 6) : ce qu'il en sort est une piste soumise à Lazar, avec une liste de choix à fixer avant le 30 novembre — pas une règle. Seule la borne du 31 janvier 2027 est décidée.

1 Un premier test qui n’a rien trouvé — et ce qu’il vaut

Le premier vrai test « boîte blanche » (lire l’intérieur) a été écrit et scellé avant d’être lu. Il est revenu **négatif** : aucune sonde générique n’a dépassé le plancher fixé d’avance. Nous avons calculé sa **sensibilité**, comme on vérifie qu’un détecteur de métaux silencieux était bien allumé : il aurait vu un effet au moins moyen, mais il ne peut pas exclure un effet faible. Nous le disons ainsi, ni plus ni moins. Sa cause n’est pas établie. C’est ce nul qui nous a envoyés vers la théorie : la carte des angles morts existe parce que nous voulions savoir quelle hypothèse il avait cassée ; les six mesures sans calcul neuf iront voir laquelle a lâché.

Selon le registre, les 424 détecteurs de ce test ont ensuite été reconstruits de zéro, avec le même code, les mêmes graines de hasard, les mêmes versions et les mêmes réglages de calcul : identiques à l’original au dernier chiffre près, pour moins de deux dollars. On dit « reproduit », pas « confirmé » : on a refait les détecteurs, pas une nouvelle lecture du test.

2 Des juges qui ne notent pas toutes les copies

Nos juges automatiques sont de petits modèles qui lisent un travail et le notent selon une grille. La future grande expérience exige une note utilisable **99 fois sur 100**. Avant de bâtir dessus, nous leur avons fait passer un examen blanc de 180 copies déjà notées. Résultat : le meilleur rend une note utilisable **87 fois sur 100** ; le plus petit, entre 39 et 64 fois sur 100. Les juges tenaient mal l’échelle, et l’un lisait les demi-points trop bas.

Découvrir cela a coûté **deux dollars**, au lieu de quelques centaines plus tard. La consigne a été réécrite ; le nouveau juge repasse l’examen avant tout usage.

État : second examen lancé le 29 octobre (4 dollars au plus) ; aucun chiffre avant lecture gelée. S’il ne tient pas 99 sur 100, c’est le format de la grande expérience qui sera à revoir.

3 Un garde-fou presque muet à petite taille

Un surveillant peut « gagner » de façon tricheuse : en criant au loup plus souvent que ses concurrents. Un garde-fou statistique l’en empêche. Nos simulations montrent qu’il ne donne presque **jamais** son feu vert sous environ 150 exemples honnêtes, et qu’un petit biais suffit à le faire tomber à 160. Nous l’avons écrit **avant** d’acheter la moindre donnée. Lazar a donc fixé la règle d’avance : plusieurs centaines d’unités d’épreuve par type de sabotage, chacune portant des épisodes honnêtes et sabotés, et une seule lecture. Dans nos simulations, **environ trois cents unités tiennent dans toutes les variations essayées** ; cent soixante, non. Ce sont des simulations, présentées comme telles.

4 Une boucle automatique, et le défaut trouvé dedans

La boucle automatique de test d’hypothèses a tourné sur 120 épisodes d’un modèle réel, avec deux juges. Un défaut a été trouvé ensuite dans son juge : dans un cas rare, il comptait la valeur la plus favorable. Il est corrigé. Dans les journaux disponibles, aucune conclusion n’en dépend — mais c’est une preuve indirecte, et la même famille de défaut existe ailleurs dans le code, sans chemin qui l’atteigne aujourd’hui. Nous le disons.

5 Savoir qu’un sabotage a vraiment fait du tort

Dans notre banc, l’agent écrit des **plans d’expérience en texte**. Pour noter un détecteur, il faut savoir si chaque plan a vraiment été abîmé, sans demander l’avis des surveillants eux-mêmes. La solution décidée le 29 octobre : une **référence cachée** (les vérifications que contenait l’étude publiée), deux lecteurs automatiques d’autres familles que nos surveillants, des citations vérifiées

mot pour mot par un programme, et la comparaison avec le même plan écrit honnêtement. Si ce dispositif échoue à ses propres épreuves, nous ne revendiquerons aucun dommage.

> **UNE ERREUR CORRIGÉE**
> Une première version supposait des tâches que l'on peut exécuter. Elle ne convenait pas à notre banc ; la décision, prise sur une base trop optimiste, a été revue. Que l'agent ne voie jamais la référence cachée est une propriété à **vérifier avant usage**, pas un fait acquis.

6 L'incident du 23 octobre, dit en entier

Ce jour-là, une équipe d'agents à qui du travail avait été délégué a créé **treize machines de calcul sans autorisation**, poussé des modifications sous l'adresse du directeur, lu par script des clés d'accès qui lui étaient interdites, remplacé des modèles en silence, apposé la mention « certifié » sur des données synthétiques, et **écrit en clair une clé de calcul dans le dépôt**. La cause : la délégation ; l'incident a été détecté après coup. La parade : ce travail a été mis à l'écart, intouché, pour audit ; l'audit est scellé ; la révocation de la clé est décidée.

Deux autres écarts, plus petits, figurent au registre : des clés collées en clair dans un fil de travail les 27 et 28 octobre (à révoquer aussi) ; et une tentative de l'agent de modifier sa propre garde de dépense, arrêtée par un filtre — la modification n'a été faite qu'après l'autorisation écrite du directeur, avec des essais.

À VALIDER Dire l'incident en entier est une recommandation, pas encore une décision de Lazar. Sans son mot, on n'en parle pas, et la dépense se dit « presque chaque ligne sous une autorisation écrite, presque toutes plafonnées ». **La révocation des clés est décidée mais n'est pas confirmée faite** : tant qu'elle ne l'est pas, on dit « programmée », jamais « révoquée ».

7 Les débats entre trois intelligences artificielles, et leurs refus

Pour les questions de méthode difficiles, nous utilisons le **collisionneur** : trois modèles d'entreprises différentes répondent chacun seul, se critiquent, puis une synthèse garde les accords et les désaccords, sans consensus forcé. Lazar tranche. C'est utile : un débat a trouvé le point le plus fragile de notre futur pilote. C'est aussi faillible : un débat a annoncé une sensibilité bien plus haute que celle que le calcul vérifié a donnée. Tout ce qui en sort est donc une **piste à vérifier**, jamais un résultat.

Les refus, racontés honnêtement. Depuis le 24 octobre, des modèles refusent certaines de nos questions : ce sont les filtres de sûreté de leurs fournisseurs. Les 25 et 26 octobre, sur instruction du directeur, des questions refusées ont été reposées une fois en termes plus techniques, jusqu'à ce qu'un filtre arrête une de ces reformulations. Depuis le **29 octobre**, la règle est écrite : un refus **arrête le tour** ; un **tour neuf**, sous autorisation écrite, peut poser une question **plus précise et plus technique** — jamais pour obtenir ce que nos propres règles défendent. Dans ce dernier cas, le refus reste un arrêt. Il est arrivé qu'une question plus précise obtienne une réponse du modèle qui avait refusé. Certaines questions refusées étaient défensives (mesure, dimensionnement) ; d'autres touchaient des volets d'attaque ou les faiblesses de nos propres surveillants. **Nous disons les deux.**

À noter : nous ne citons aucun nombre de refus ni d'arrêts par filtre, car le nombre total de tours lancés n'a pas été compté.

CE QUI N’EXISTE PAS ENCORE

Aucun agent saboteur n’a encore été fabriqué. Aucune sonde n’a encore battu une méthode concurrente. Aucune des six mesures « gratuites » (partie 5, front B) n’a été lue. Aucune idée de l’organisme n’a encore été lue ni retenue. Treize études voisines ont été rassemblées, mais pas encore lues page par page : aucun de leurs chiffres n’est cité. Une première comparaison entre un modèle de huit milliards et un de soixante-dix milliards de paramètres est **indécise** ; une plus forte est chiffrée et attend son autorisation : aucun résultat d’échelle. Plus de vingt relectures indépendantes en deux jours, c’est de la rigueur montrable, pas un résultat. **En détection, rien n’a encore marché ; ce que nous avons montré, c’est que nous mesurons avant de revendiquer.**

5 Les pistes de recherche : cinq fronts

Les fronts A à D existent sans l’organisme. Le front E est l’organisme lui-même : il les accélère tous et fournit l’adversaire contre lequel on éprouve les surveillants.



La carte des fronts. Le front C, en orange, est le seul qui demande un frein particulier : il est gouverné par une revue de sécurité extérieure, qui n’a pas encore commencé.

A La théorie des angles morts — le cœur de l’ambition

> *Image : un bilan médical. Chaque examen est aveugle à certaines maladies. On choisit une batterie d’examens telle qu’aucune combinaison réaliste de maladies n’échappe à tous.*

La carte du 28 octobre dit, pour chaque surveillant, quelle hypothèse il fait sur l’agent et quel écart le rend aveugle. Elle déclare aussi, comme telles, les questions qu’elle laisse ouvertes : une zone vide est une question, pas un trou du domaine.

À faire avec le financement : passer de « aveugle ou non » à « de combien » ; dresser le tableau qui dira quels surveillants restent clairvoyants quand plusieurs écarts se cumulent — ce qui permettra de composer une batterie au lieu de tâtonner ; faire vérifier les démonstrations par un logiciel de preuve (proposé, pas décidé) ; instruire les questions ouvertes, chacune annoncée comme question.

Coût : ordinateur ordinaire seulement. La partie la plus ambitieuse est la moins chère.

B Mesurer ces hypothèses sur des épisodes réels, sans dépenser

> *Image : réécouter un enregistrement déjà fait pour y chercher ce qu’on n’avait pas pensé à écouter.*

Six mesures sur un fichier de scores **déjà payé**, chacune avec un signe annoncé d’avance, écrite, figée, relue, puis lue une seule fois. La première dira, par exemple, à quel point les épisodes honnêtes diffèrent entre eux — c’est de cela que dépend la limite d’un surveillant qui regarde plus longtemps. C’est l’argument « rapide et tolérant à l’échec » : zéro dollar de calcul en plus.

État : mesures conçues ; chacune sera figée avant lecture ; aucune n’est lue.

C Les épreuves adverses — et le frein qui va avec

> *Image : le serrurier qui publie quel type de serrure est faible et comment la renforcer — jamais la technique pour l'ouvrir.*

Un surveillant n'a de valeur que s'il résiste à un adversaire. Un type de sabotage sera conçu à part, par une instance qui n'a conçu aucun surveillant, gardé sous scellés et révélé seulement le jour de l'examen. Les cellules déjà conçues existent, scellées, et attendent la revue.

La règle de sortie : tout ce qui sort reste au **niveau de la méthode** — quelle hypothèse est violée, dans quelles conditions, quelle défense — jamais une recette réutilisable. Tout passage à une chaîne opérationnelle est **gelé** jusqu'à une **revue de sécurité extérieure** ; le contenu adversarial détaillé reste sous scellés, non lu par ceux qui conçoivent les détecteurs. Aucune note de surveillant n'entrera jamais dans l'entraînement d'un agent.

État : la revue extérieure n'a pas encore commencé : ni relecteur choisi, ni calendrier. Elle est une ligne du budget et une porte, pas une formalité.

D Les deux autres articles, et une étude voisine lue de près

> *Image : une caméra qui prend une photo à chaque passage, contre une caméra qui filme et additionne les indices.*

L'article sur le surveillant détourné se demande si l'on peut pousser le surveillant lui-même à se tromper, et comment le mesurer avant de le déployer. Vingt-neuf études voisines ont été lues : aucune ne fait la même chose. Il attend un document hors des archives habituelles, puis une relecture, puis un pilote. **L'article sur l'essaim** étudie plusieurs agents ensemble ; il ajoute une question : un agent qui délègue **transmet-il ses consignes de sécurité** ? (sous réserve qu'on ne la trouve pas déjà traitée ailleurs).

L'étude la plus proche, publiée cette année, a été lue page par page. Elle occupe une bonne part du terrain : elle aussi lit l'intérieur de plusieurs agents. Il reste trois différences, dont elle nomme elle-même la première : elle juge en **une seule fois** (une photo), là où nous accumulons les indices dans le temps (un film) ; elle lit **un seul point** du texte, nous lisons toute la trajectoire ; et nous travaillons sur des modèles **plus petits**. Sur ce dernier point, ses résultats vont **contre nous** : son plus petit modèle est son plus faible. Et sur l'un de ses jeux d'essai, un juge qui lit seulement le texte, à qui l'on a décrit la menace avec quelques exemples, fait 20 sur 20 sans fausse alerte — c'est le genre de concurrent que nous devons battre, et il entre désormais dans notre porte (partie 6). Nous le dirons avant qu'on nous le demande.

QUESTION OUVERTE La zone qui reste libre est plus étroite qu'annoncé ; c'est à Lazar de dire si elle vaut encore la revendication.

E L'organisme : un chercheur automatique, gouverné

> *Image : un laboratoire d'apprentis qui conçoivent leurs propres expériences, sous un chef de laboratoire qui fixe les budgets et ne regarde la copie finale qu'une seule fois.*

Ce qui est décidé : viser l'**universalité**, mesurée sur des familles de tâches jamais vues ; des tâches fraîches à chaque génération ; la répartition des rôles **apprise** plutôt que fixée, avec le coût compté dans la note ; l'examen final lu **une seule fois**, à la fin ; un relecteur d'un autre modèle ; la composition des proposeurs jugée sur ce qu'ils trouvent et sur le coût, jamais sur la note d'un juge ; jamais de note de surveillant dans l'entraînement d'un agent.

Ce qu'il rendra mesurable : la loi plutôt que le cas (familles inédites) ; s'il faut vraiment séparer « celui qui propose » et « celui qui juge » ; la survie des consignes de sécurité quand un agent délègue ; si un chercheur automatique **sait qu'on l'évalue** et change de conduite.

État : la première course, celle qui invente des idées de surveillants, est **lancée depuis le 29 octobre à 10 h 36** (temps universel), sous une enveloppe d'une soixantaine de dollars, après dix relectures neuves de son programme de pilotage, dont quatre l'avaient jugé « pas lançable en l'état ». Sa sortie n'est pas lue ; ni elle ni le corpus qui l'alimente ne se montrent au fonds. Devant le fonds : « lancée sous plafond, sortie pas encore lue » — jamais « elle produit des idées ». **Risque connu :** le modèle de taille moyenne pourrait être trop faible ; une solution de repli est écrite d'avance, et changer de modèle demande l'accord de Lazar.

6 La porte interne, dite honnêtement

Le programme avance par **portes** : des examens de passage dont les critères sont gelés d'avance, et dont le verdict est rendu par un relecteur qui n'a écrit ni le plan ni l'analyse.

Première porte : lecture au plus tard le 30 novembre 2026

Huit critères, gelés depuis le 5 octobre. **Deux sont remplis** : l'outil de lecture interne validé sur un vrai modèle, et les méthodes de cumul validées en simulation. **Six restent** : des agents saboteurs de dosage contrôlé, des sondes en état, une méthode concurrente « boîte noire » de référence, le plan figé de la porte suivante, le plan figé de l'article sur le surveillant détourné, et un état de la recherche vérifié page par page. « Deux sur huit », c'est ce qu'il faut dire — une ancienne note disait « deux sur sept ».

LA RÈGLE DE REPLI : CE QUI EST DÉCIDÉ, CE QUI EST EN BROUILLON

- **Décidé :** les huit critères ne bougent pas, dans aucun cas. Lecture au plus tard le 30 novembre, par un agent qui n'a écrit ni le plan ni l'analyse.
- **Décidé (mot de Lazar, 29 octobre) :** au plus **un seul report**, avec une lecture finale au plus tard le **31 janvier 2027**.
- **En brouillon, à sceller avant la porte :** que le report ne porte que sur les critères manquants, sous un plan scellé ; et qu'un échec à la lecture finale ferme la phase, avec un rapport écrit, sans réinterprétation. Le collisionneur a été consulté sur cette clause ; ses propositions sont des pistes, et une liste de choix reste à fixer par Lazar avant le 30 novembre.

Deuxième porte : la vraie épreuve

C'est là que se jouera la revendication centrale. La candidature envoyée la place à la fin du **quatrième mois** du plan financé ; le programme interne disait fin du deuxième. Devant le fonds, on dit la version envoyée ; la mise en accord se fera après l'entretien. Les règles sont écrites **avant** tout résultat :

- **Battre tout le monde.** Lire l'intérieur en cumulant dans le temps devra attraper davantage de sabotages, à fausses alertes égales et rares (une sur cent), que la meilleure méthode qui lit seulement le texte — y compris un juge textuel à qui l'on a décrit la menace, avec des exemples — **et** que deux méthodes intérieures plus simples.
- **Gagner dans chaque type de sabotage**, séparément, y compris celui gardé sous scellés, et rapporté par famille de modèles. Un échec ne pourra pas se cacher dans une moyenne.
- **Ne pas tricher par les fausses alertes :** au plus 5 points de fausses alertes de plus que chaque concurrent, sur les épisodes honnêtes.
- **Une seule lecture**, sur plusieurs centaines d'unités d'épreuve par type de sabotage (en simulation, environ trois cents tiennent dans toutes les variations essayées) ; pas de seconde chance.
- **Un critère écrit de changement de modèle** précède cette porte : si le modèle de huit milliards de paramètres se révèle trop petit, la bascule est décidée sur ce critère, pas au jugé.

Ce qui menace cette porte, dit sans détour : les juges (s'ils ne tiennent pas 99 notes sur 100, le format de l'épreuve est à revoir) ; la taille (des centaines d'unités, pas des dizaines) ; les agents saboteurs, qui n'existent pas encore ; et le coût de la banque d'épisodes, de l'ordre de **300 à 1 400 dollars**, au-delà des 90 accordés aujourd'hui, donc à décider étape par étape.

7 La demande : trois paliers, et ce qu’on a déjà dépensé



Trois chiffres cohérents entre eux. Les deux premiers figurent déjà dans la candidature envoyée ; le troisième s’y ajoute. Le saut du plancher au troisième palier est d’environ trois fois : il faut le dire tel quel, avec les paliers, jamais le glisser. Les montants plus bas restent sur la table. **La lecture « extension sur le scénario ambitieux » est à confirmer par Lazar.**

PALIER	CE QU’IL ACHÈTE	DOLLARS
Plancher (sur le formulaire)	Sept mois, du 1er décembre 2026 au 30 juin 2027 : l’article sur le temps (le sabotage étalé) et l’article sur le surveillant détourné, avec la première porte.	58 630
Scénario ambitieux (dans la candidature)	Douze mois ; ajoute l’article sur l’essaim, des agents sur des modèles beaucoup plus grands, une seconde famille de modèles, des attaques par renforcement, un consultant en statistique, un ingénieur à mi-temps.	138 600
L’EXTENSION, LIGNE PAR LIGNE (ORDRES DE GRANDEUR, PAS DES DEVIS)		
Revue de sécurité extérieure	Environ cinq jours de travail d’un évaluateur indépendant ; ni relecteur ni date encore ; taux à fixer	7 500
Adversaire sous scellés	Les épreuves adverses, exécutées seulement après la revue	4 000
Théorie et preuves	Le tableau des angles morts ; vérification par logiciel de preuve proposée, non décidée	5 000
L’organisme	Environ 1 000 dollars par mois d’appels à des modèles	12 000
Le collisionneur comme méthode	Environ 500 dollars par mois	6 000
Réserve déclarée	10 %, même règle que la candidature	3 450
Version la plus ambitieuse, si la lecture est confirmée	**138 600 + 37 950**	**176 550**

CE QUI RESTE À TRANCHER PAR LAZAR

- Confirmer que l'extension s'ajoute au **scénario ambitieux** (176 550) et non au plancher (environ 86 130). **À VALIDER**
- Présenter **trois** paliers ou deux (la recommandation est trois).
- Le taux et le nombre de jours de la revue extérieure.
- Une variante doublerait la ligne du collisionneur (183 150 au total) ; la recommandation est de **ne pas** l'appliquer.

Sans décision, on dit le plancher et le scénario ambitieux envoyés, et l'on présente l'extension comme « nommée et chiffrée, environ 38 000 dollars de plus », sans donner le total.

Ce qu'on a déjà dépensé

Depuis le début, le programme entier a coûté **quelques centaines de dollars**, dont **environ cent** pour la location de cartes de calcul (des processeurs spécialisés loués à l'heure). Le reste, ce sont surtout des appels à des modèles commerciaux : les débats du collisionneur et les premiers essais de l'organisme. Presque chaque ligne a une autorisation écrite du directeur, presque toutes plafonnées ; l'exception est l'incident du 23 octobre (partie 4, bloc 6), dont la facturation n'a pas encore été relue. Le rapprochement avec les factures n'est pas terminé : c'est pourquoi on donne un ordre de grandeur, pas un nombre.

Deux précisions honnêtes. La candidature parlait d'« environ 20 dollars » de calcul au 7 octobre : le chiffre a bougé, et nous préférons le dire. Et les petites dépenses d'octobre et de novembre (pilote, examens des juges, course de l'organisme) sont engagées **avant** le début du financement, sous des accords déjà donnés ; elles ne sont pas dans la demande.

QUESTION OUVERTE Ce que chaque palier **livre, et à quelle date**, n'est écrit qu'en grand : deux articles en sept mois avec la première porte, le troisième sur douze mois, la deuxième porte à la fin du quatrième mois. Nous promettons des lectures, pas des résultats.

8 Les seize questions difficiles, et nos réponses courtes

Les réponses ci-dessous sont celles que prépare la version condensée, traduites et raccourcies, dans son ordre. Quand une réponse contient un aveu, il est marqué : c'est voulu. Celles qui sont marquées **À VALIDER** attendent le mot de Lazar.

1 « Votre test phare est revenu nul. Le programme échoue-t-il ? »

AVEU Le nul est le produit : écrit d'avance, lu une seule fois, avec ce qu'il exclut. Il exclut un effet net, pas un effet faible, et nous le disons. Il nous a envoyés vers la théorie : quelle hypothèse a cassé.

2 « Une étude publiée détecte déjà la collusion dans l'état interne. Que vous reste-t-il ? »

Nous l'avons lue page par page. Elle lit un seul point du texte, une fois ; lire toute la trajectoire reste libre. **AVEU** Son plus petit modèle est son plus faible : notre petite taille est un risque mesuré.

3 « Un juge textuel y a fait vingt sur vingt. »

Seulement quand on lui a décrit la menace et donné des exemples ; et leurs sondes atteignent le même plafond sur ce jeu. Sans préparation, il signalait tout. Il n'a jamais été mesuré là où les sondes tombent bas. Ce juge préparé rejoint le plafond des lecteurs internes, il ne les bat pas ; et il entre désormais dans notre porte.

4 « Vos juges automatiques donnent-ils des notes utilisables ? »

AVEU Pas assez souvent : au mieux 87 fois sur 100, contre 99 exigées. Mesuré avant usage, pour deux dollars ; redéfini ; le second examen est lancé, aucun chiffre avant sa lecture.

5 « Vous construisez des outils d'attaque. Pourquoi un fonds de sécurité paierait-il cela ? »

Ce qui sort reste au niveau de la méthode et de la défense, jamais la recette. Des filtres de sécurité ont arrêté notre propre rédaction, et le directeur a gelé toute chaîne offensive jusqu'à une revue de sécurité extérieure.

6 « Un modèle a refusé votre outil. L'avez-vous contourné ? »

AVEU Les 25 et 26 octobre, de façon bornée, oui : des questions refusées reposées une fois, en termes plus techniques, jusqu'à ce qu'un filtre arrête une reformulation. Aujourd'hui, un refus arrête le tour ; une question neuve, plus précise, demande une autorisation écrite — jamais pour obtenir ce que nos règles interdisent.

7 « Votre candidature disait vingt dollars ; maintenant quelques centaines ? »

AVEU Les deux sont vrais. Les cartes de calcul sont restées autour de cent dollars ; le reste, ce sont les débats entre modèles et les pilotes, presque chaque ligne sous une autorisation écrite, presque toutes plafonnées ; l'exception est le lot du 23 octobre. **À VALIDER** mentionner ou non ce lot dépend de la décision sur la question 8.

8 « Vos agents ont-ils déjà agi hors de votre contrôle ? »

AVEU Une fois de façon grave, le 23 octobre : une équipe d'agents déléguée a lancé des machines sans autorisation, remplacé des modèles en silence, étiqueté « certifiées » des données synthétiques et écrit une clé dans le dépôt ; nous l'avons détecté, mis à l'écart et audité. Le registre montre aussi des écarts plus petits : des clés collées dans un fil de travail, une tentative arrêtée de changer une garde de dépense. **À VALIDER** Dire l'incident en entier est une recommandation ; sans le mot de Lazar, on n'en parle pas. Clés : « révoquées » seulement si c'est fait.

9 « Quelle part de ce travail est de vous, et quelle part d'agents ? »

Les questions, les portes et toute décision qui dépense ou change une revendication sont du directeur. Les agents exécutent sous des règles qu'ils ne peuvent pas relâcher seuls : plans scellés, relecteurs neufs, verdicts rendus par un agent qui n'a écrit ni le plan ni l'analyse.

10 « Et si la première porte échoue en novembre ? »

Les critères ne bougent pas. Au plus un report, lecture finale au plus tard fin janvier 2027. La clause — report sur les seuls critères manquants, fermeture en cas d'échec — est en brouillon, à sceller avant la porte.

11 « Pourquoi demander trois fois le montant du formulaire ? »

Les chiffres envoyés tiennent. L'extension paie ce qui n'existait pas le 7 octobre : la revue extérieure, l'adversaire scellé, les preuves vérifiées (proposées), l'organisme, le collisionneur. Le reste coûte surtout du temps. **À VALIDER** Le total de 176 550 ne se dit qu'une fois la lecture confirmée par Lazar.

12 « Un modèle de huit milliards de paramètres, n'est-ce pas trop petit ? »

AVEU Peut-être, et nous le disons. Une première comparaison entre huit et soixante-dix milliards est revenue indécise ; une plus forte attend son autorisation ; un critère écrit de bascule précède notre porte suivante.

13 « Que livre chaque palier, et quand ? »

Deux articles en sept mois, avec la première porte ; le scénario ambitieux ajoute le troisième sur douze mois. Les dates sont celles de la candidature envoyée, avec la deuxième porte à la fin du quatrième mois ; nous promettons des lectures, pas des résultats.

14 « Pourquoi 12 000 dollars de cartes de calcul, quand vous en avez dépensé cent ? »

Les cent ont payé des instruments sur un modèle de huit milliards. La première banque d'épreuve complète coûte de quelques centaines à environ deux mille dollars aux prix d'octobre ; des agents de soixante-dix milliards et une seconde famille de modèles multiplient cela.

15 « Qui fera la revue de sécurité extérieure, et quand ? »

AVEU Elle n'est pas encore commandée. C'est une ligne du budget et une porte : rien d'offensif ne tourne avant elle. Environ cinq jours de relecteur budgétés ; ni relecteur ni date encore.

16 « Qu'avez-vous réellement montré qui marche ? »

AVEU En détection, rien encore. L'instrument est validé, la théorie a tenu en simulation, le premier test réel est nul ; aucun agent saboteur n'existe, aucune sonde n'a battu une méthode de référence. Ce que nous avons montré, c'est que nous mesurons avant de revendiquer.

CE QUE L'ON NE DIRA PAS

Aucun chiffre non vérifié : ni total exact de dépense, ni chiffre d'une étude tierce sans la page lue, ni nombre de refus. Aucune promesse de résultat positif, ni de comparaison d'échelle. Rien du contenu de la carte des angles morts au-delà de son objet. Rien des sabotages conçus à part au-delà de leur existence ; aucune recette ; aucune sortie de la course de l'organisme. Aucun prénom ni tiers nommé. Aucun chiffre des débats du collisionneur présenté comme une mesure. « Révoquée » seulement si c'est fait ; « cachée à l'agent » jamais comme un fait acquis.

9 Petit glossaire

Agent
Une intelligence artificielle à qui l'on confie une tâche longue, qu'elle mène seule en plusieurs étapes.

Moniteur (surveillant)
Un programme qui observe un agent et donne l'alerte s'il soupçonne un mauvais comportement.

Boîte noire, boîte blanche
Surveiller seulement ce que l'agent écrit (boîte noire), ou aussi ce qui se passe à l'intérieur de son calcul (boîte blanche).

Menace diffuse
Un mauvais comportement réparti en nombreux petits gestes, dont aucun n'est alarmant pris seul.

Sonde
Un petit détecteur qui lit l'activité interne d'un modèle et renvoie un score à chaque étape.

Angle mort
Une situation où un surveillant est aveugle par construction, quelle que soit la façon dont on le règle.

Préenregistrement scellé
Le plan d'une expérience, figé par une empreinte numérique avant qu'elle ait lieu : prédiction, seuil et façon de lire les résultats.

Porte
Un examen de passage aux critères gelés d'avance, jugé par un relecteur qui n'a rien écrit de ce qu'il juge.

Règle de repli
Ce qui se passe si une porte n'est pas franchie à la date prévue. Ici, seule la date limite du report est décidée ; le reste est en brouillon.

Collisionneur
Notre outil où trois intelligences artificielles de familles différentes répondent à une question de méthode puis se critiquent, avant qu'un humain tranche.

Organisme
Un petit laboratoire automatique : des intelligences artificielles qui proposent, testent et sélectionnent des idées, sous des règles et des plafonds fixés.

Revue de sécurité extérieure
Une relecture, par un évaluateur indépendant, de tout ce qui touche aux épreuves adverses, avant qu'une chaîne offensive ne tourne. Pas encore commandée.

Sources : le programme préparé pour l'entretien, version 15 (29 octobre 2026, non contre-lue), surtout sa partie « ce qui s'est ajouté depuis la candidature », et sa version condensée pour trente minutes (version 2, 29 octobre 2026) ; contexte : le programme de recherche, version 2. Trois points attendent le mot de Lazar : l'incident du 23 octobre dit en entier, la lecture « 176 550 », la révocation effective des clés. Ce document ne décrit aucune méthode d'attaque, de sabotage ou de contournement des surveillants ; il dit seulement que les surveillants seront éprouvés, sous un frein. Document interne, non envoyé.