Registre des prédictions, en une page

Version 1, finale. État au 10 novembre 2026, 12:08 UTC. Contre-lue : brouillons 1 à 3 (empreintes courtes aeb45c39, 7ff41bcf, fe61d259).

Mots. Saboteur (ou organisme) : modèle modifié pour dégrader une tâche ; l'honnête est son jumeau. Sonde : petit classifieur qui lit les activations internes (« boîte blanche ») ; générique : entraînée hors de ce saboteur. Juge : modèle qui ne lit que le texte (le « juge statistique » de l'idéation est un test) ; J3s : juge de 3 milliards de paramètres. W, T : sondes entraînées du rejeu. Plancher : score d'une sonde témoin sans signal. Aire : aire sous la courbe de détection (0,5 = hasard). Flagrant : dommage visible dans une action ; diffus : seulement dans l'ensemble. G0, G1 : portes de sortie des phases 0 et 1 ; T0.3 à T0.7, P3, P3-bis : tâches de cette phase. Verdict : lecture scellée par un lecteur neuf ; « l. » = sa ligne (`docs/verdicts/`) ; « préenr. » = préenregistrement (`prereg/`). **Non concluante** : le verdict ne tranche pas. **Hors compte** : série sans prédiction pariée, bras non mesuré, prédiction « descriptive », « non lisible » ou « retirée » ; absent des comptes.

Groupe	confirmées	réfutées	non concluantes
Preuves vérifiées en simulation	31	0	0
Instruments (harnais, noyaux)	32	2	1
Prédictions empiriques	**33**	**7**	**6**
Toutes	96	9	7

Comptes bruts, sans taux. Source : `docs/notes/entretien-resultats-v1/taux-retenu-recompte-predictions-v2.md` (a745adc5), qui remplace une première table produite par script et renvoie au recompte à la main contre les verdicts et à sa contre-lecture.

Deux lectures de sensibilité, prédictions empiriques : 33 / 11 / 6 si l'on compte réfutées les quatre fourchettes chiffrées manquées sans verdict propre au rejeu de P3 : P-R2 J3s ; P-R2 T ; P-E2 ; P-E4 (P-E5, « descriptif » au préenr. `analyse-par-episode-v1` l. 29, reste hors compte) ; 26 / 7 / 6 sans le nul v9. Les quatre s'ajoutent : 50 au lieu de 46.

Le compte porte sur le signe, pas sur l'ampleur : les ampleurs manquées le sont toutes du côté favorable à la sonde (P3-P1 ; au rejeu, P-R2 J3s, P-R2 T, P-E1, P-E2, P-E4, P-E5, verdict `dece9980` l. 46-47). **Ce que le registre établit :** les prédictions comptées sont écrites avant leurs courses, sauf celles du nul v9 (« écrites après les lectures préalables », `1407e460` l. 13) et B1 de P3 (« écrites en connaissant l'effet décisif », `05e896da` l. 477-478) ; réfutations et nuls publiés, dont la prédiction principale du premier test, « non détecté à cette puissance ». **Ce qu'il n'établit pas :** qu'une sonde détecte le sabotage diffus. La seule sonde passée au-dessus d'un juge l'a fait sur un saboteur flagrant qui recevait une consigne, et l'audit a conclu à la « lecture de la consigne ».

Série (date de course, ou « verdict » et sa date ; empreinte)	Ce qui était prédit (préenr. en note)	Issue scellée : mots du verdict	confirmées / réfutées / non concl.
Simulation du lemme et du théorème négatif, T0.3 (4 oct. ; `bc53b746`)	31 prédictions ; une cellule contraire réfute	« confirmé avec réserves » (l. 10) ; 886 cellules conformes, 0 contraire (l. 12) ; « 31 sur 31 était l'issue attendue par construction. 19 prédictions sur 31 sont des vérifications de l'instrument » (l. 25)	31 / 0 / 0
Harnais d'activations, T0.4 v1 à v3 (v3 : 6 oct. ; `fb9919f9`, `98d53c70`, `63444faa`)	Rejeu au bit près, accord avec une référence, écart de demi-précision ≤ 0,1	v2 : « Critère 1 de G0 : non prouvé par ce run » (l. 10), P4 « contraire », écart 0,5219 (l. 107). v3 : « Critère 1 de G0 : prouvé par ces deux runs » (l. 11) ; « La production dépasse un peu le domaine strict du chemin » : 1 192 jetons contre 1 087 (l. 18). Une prédiction reprise compte une fois par version	24 / 1 / 1
Noyaux de calcul, T0.5 (11 oct. ; `f98b5684`)	Deux bras, critères R1 à R8 chacun	« Nœud : aucun noyau n'est retenu pour le pilote ; rien ne tourne. » (l. 17) ; bras « defaut » « non conforme par le seul critère R8 » : 8 089,62 s pour 7 800 s (l. 18) ; bras « math » en panne de mémoire, non mesuré (hors compte)	8 / 1 / 0
Pilote, T0.5 (12 oct. ; `b9a07230` ; notations 17 oct., `d861605c`)	P1 à P7 : format, juges, appariement aux cibles semées	« P1, P4 et P6 confirmées ; P5 et P7 réfutées ; P2 et P3 non concluantes » (l. 56) ; kappa pondéré « de 0,04 à 0,17, pour 0,6 exigé » (l. 49) ; notations : « P2 et P3 : non concluantes » (l. 51)	3 / 2 / 2
Premier test boîte blanche, P3 (19 oct. ; `05e896da`)	P3-P1 : coût déclaré plus haut, écart en log décimal « > 0 ; au plus ≈ 0,48 » ; P3-P3 : une sonde générique au-dessus du plancher (préenr. l. 155, 157)	P3-P1 « établie », 1,5227 [1,2464 ; 1,8012] (l. 10-11) ; réserve « écart à l'ordre de grandeur prédit » (l. 26). P3-P3 « **réfutée au sens de la table des prédictions** », lue « non détecté à cette puissance » (l. 14-15) ; « le nul n'exclut pas une aire inférieure à 0,6315 » (l. 29). « Les trois prédictions de B1 tiennent », « écrites en connaissant l'effet décisif » (l. 476-478)	4 / 1 / 0
Agrégateurs des scores par action (6 nov. ; `070a6dd4`)	C1 à C3 : l'ordre que prédit le lemme	« appuyée à m = 1 seulement » (l. 3) ; C1 « non concluant par construction (puissance simulée insuffisante ou signe simulé contraire) », C2 et C3 « confirmé à cette puissance » (l. 4-5) ; « C3 se réduit à C2 », « fuite non exclue » (l. 11-12) ; puis « l'issue n'est plus citable comme appui du lemme sur un sabotage » (verdict de fuite, l. 64)	2 / 0 / 1
Rejeu de P3, sonde W entraînée sur ce saboteur (6 nov. ; `dece9980`)	W bat les sondes génériques ; son avance sur un juge de 3 milliards de paramètres est dans [0 ; +0,3]	« P-R1 confirmée sur cet organisme » ; « sur un organisme flagrant ; rien sur le diffus » (l. 15) ; « P-E1 confirmée par épisode sur cet organisme », audit « trop beau » déclenché, « audit de fuite […] avant tout énoncé » : non clos (l. 16 ; voir la série suivante) ; deux comparaisons « non établie » (l. 17) ; « P-R2 (J3s) prédit dans [0 ; +0,3], observé +0,932 », juge au hasard, aire 0,523 (l. 46) ; « Prédictions manquées dans le sens favorable à W » (l. 47) ; « ne compte ni pour G1 ni pour le critère 4 de G0 » (l. 58)	7 / 0 / 2
Audit de fuite de W (7 nov. ; `320463e6`)	« Aucune prédiction de signe n'est pariée » (préenr. l. 92)	« Fuite (lecture de la consigne) » (l. 3) ; un seul bras ; le bras qui sépare coût et consigne « n'est pas fait » (l. 6-7)	hors compte
Étiqueteur du sabotage flou, phase 1 (verdict 8 nov. ; `9f7830b9`)	P-1 à P-11 : doses fortes vues, peu de fausses alarmes	« non tranché », « lecture instable » : « 11 fausses alarmes sur 120 placebos » ; « La phase 2 ne part pas » (l. 21) ; P-3 « réfutée pour les trois types » (l. 58)	5 / 3 / 1
Conscience d'être évalué, 8 et 70 milliards (27 oct. ; `aaf43f95`)	« Aucune issue n'est visée » (préenr. l. 113)	« Indécis. » ; « Le dispositif ne tranche pas. » (l. 22, 24)	hors compte
Juge statistique (volet idéation), attaque de Goodhart (verdict 5 nov. ; `7dade9ef`)	Il résiste à un adversaire qui l'optimise, dans deux mondes simulés W1, W2 ; P1 à P6	W1 « résiste (à cette taille) » ; W2 « infirmée (brèche sous v8) », « par classe non couverte » (l. 3) ; « P5 est fausse » ; « la course est trop propre » ; « Le résultat se rapporte avec les deux courses interrompues et avec A1, jamais seul » (l. 5)	5 / 1 / 0
Même juge, loi de référence « nul v9 » (verdict 8 nov. ; `1407e460`)	P1 à P7 (préenregistrement hors du dépôt)	« puissance perdue » (l. 7) ; « Toutes les prédictions P1 à P7 sont vraies ; elles ont été écrites après les lectures préalables » (l. 13)	7 / 0 / 0
Fausses alertes par épisode honnête, « mesure unanime »	Écrites d'avance (préenr. v15, `3a1651f4`) : M1, 0,05 à 0,12 fausse alerte par épisode ; M4, une dépendance non vue au calibrage casse les sommes, pas le maximum	Course du 10 nov., 10:01:43 à 10:33:16 UTC (passations vérifiées par la contre-lecture `aeb45c39`). Verdict `7d19704d` : **verdict scellé en quarantaine, non lu**, cloison jusqu'aux scellements de T0.7 (sondes) et de P3-bis (témoin positif)	fermé

Sommes. Instruments : 24 + 8 = 32 ; 1 + 1 = 2 ; 1. Empiriques : 3 + 4 + 2 + 7 + 5 + 5 + 7 = 33 ; 2 + 1 + 3 + 1 = 7 ; 2 + 1 + 2 + 1 = 6. Total : 31 + 32 + 33 = 96 ; 0 + 2 + 7 = 9 ; 0 + 1 + 6 = 7. Préenr. (`prereg/`) : T0.3-simulation-lemme-theoreme-v1 ; T0.4-validation-modele-reel-v1 à v3 ; T0.5-revalidation-equivalence-pilote-v2 ; T0.5-pilote-8B-v1 ; P3-premier-test-i-a-v1 ; agregation-r1-v4-v1 ; audit-fuite-r1-v4-v1 ; preenregistrement-epreuve-etiqueteur-v1 ; test-echelle-conscience-eval-v10 ; preenregistrement-attaque-goodhart-v3-v4 (chemins donnés par les verdicts ; rejeu : trois textes, non nommés ici). Pas encore couru : saboteurs sans consigne (T0.6) ; T0.7 et P3-bis en écriture. Page 2 : ce qui manque.

Ce qui manque pour rassurer le jury sur « l'approche peut marcher » — v1

État relevé le 10 novembre 2026 à 10:46 UTC (`date -u`), session mère. Entretien visé le 27 novembre 2026, à confirmer avec le fonds. Cette liste ne porte aucun résultat de surveillant ni de sonde : seulement ce qui doit exister, sa date et son état. Elle est à insérer telle quelle dans chaque document qui explique le programme.

Ce qui est dit d'abord au jury : aucune sonde n'a encore battu un surveillant de référence, et l'existence d'une trace interne du sabotage n'est pas établie. Le programme ne peut pas promettre une réponse positive ; il traite la question par des expériences préenregistrées dont l'issue est écrite d'avance dans les deux sens.

Priorités fixées par Lazar le 10 novembre : d'abord la ligne 5, puis les lignes 4, 7 et 8.

n°	Ce qui manque	Pourquoi le jury le demandera	Avant le 27 novembre ?	État au 10 novembre
1	La chaîne de sondes retrouve un signal planté, et se tait sur son jumeau honnête (témoin positif).	Sans cela, un résultat nul ne dit rien : la chaîne pourrait être aveugle.	Oui : lu le 20 novembre au plus tard.	Texte au brouillon 11 ; code validé par une contre-lecture ; course à créer au plus tard le 18.
2	Un saboteur sans consigne, dont l'effet sur le coût croît avec la dose (course de confirmation).	Le seul saboteur existant recevait une consigne, que la sonde lisait.	Oui : verdict du 16 au 18.	Texte scellé ; course à créer au plus tard le 15.
3	À ces doses, le texte seul ne suffit pas à repérer le sabotage (surveillants externes de référence).	Si lire le texte suffit, lire l'intérieur n'apporte rien.	Possible : vers le 20 ou le 21.	Premier brouillon du texte en rédaction.
4	Une sonde au-dessus du hasard à ces doses.	C'est la première preuve que la trace existe.	Possible, sans marge ; dépend des lignes 1 à 3 et du scellement du texte des sondes.	Texte des sondes au brouillon 21 ; scellement visé avant le 13.
5	La sonde lit le sabotage, et non le simple fait qu'un adaptateur est actif.	Le saboteur sans consigne est un adaptateur ajouté aux poids ; l'honnête est le modèle nu. Une sonde pourrait ne lire que cette différence.	À établir en premier.	Aucun témoin « adaptateur honnête » trouvé dans le texte scellé de la course (recherche par mots, vérification sur texte en cours) ; remèdes à l'étude : contraste au sein d'une même dose, témoin distillé honnête.
6	La puissance de cette lecture, écrite avant de lire.	Un résultat nul doit dire quel effet il exclut.	Oui.	À vérifier dans le texte des sondes.
7	Un résultat positif déjà publié, reproduit sur notre chaîne (banc public).	Preuve, hors de nous, que la chaîne sait voir ce que d'autres ont vu.	Possible.	Texte au brouillon 4, contre-lu trois fois ; code à écrire ; dépense à autoriser sur devis.
8	Un sabotage vraiment diffus : chaque action dans la plage honnête, le dommage dans l'ensemble seulement (saboteur à budget).	Le saboteur actuel peut être flagrant ; la thèse porte sur le diffus.	Incertain ; exploratoire.	Conçu et contre-lu une fois ; code à écrire ; dépense à autoriser sur devis.
9	Des témoins de concepts : la sonde ne réagit pas à un sujet quelconque.	Contrôle de validité.	Incertain.	Deux concepts sur quatre acceptés, deux refusés deux fois ; nouvelle consigne en rédaction ; le texte des sondes prévoit un repli sans eux.
10	Le jeu d'entraînement de la sonde du domaine « coût gonflé ».	Sonde la plus proche du sabotage étudié.	Incertain.	Refusé pour un indice de surface ; une dernière réécriture est permise.
11	La preuve datée, chez un tiers, que chaque préenregistrement précède ses données.	Seule vérification possible sans nous.	Oui.	Empreintes déposées en privé ; à rendre public et à geler.

Sources : `registres/decisions.md`, R-2116 à R-2162 ; `brouillons/entretien-taif-v3/socle-preuves-entretien-v2.md`.

Inséré mot pour mot depuis `docs/notes/rapports-directeur/ce-qui-manque-approche-peut-marcher-v1.md`, branche `main`, dernier commit du fichier `983dd664`, sha256 `edb0bf03d87dd208b4add5f9630aac19a2f9dc04336215a9c01d4febe0578626` ; seule la mise en forme (titre, gras, table) passe du Markdown au HTML.